Coleta, Tratamento e Análise Exploratória de Dados via Web Scraping no Mercado de Livros Online

Matheus de Oliveira Matias Silva
Desenvolvimento de Sistemas Multiplataformas
FATEC — Araras, SP, Brasil
matheus.silva92@aluno.cps.sp.gov.br

Abstract—Este artigo apresenta a Fase 1 do trabalho prático da disciplina de Mineração de Dados, cobrindo seleção da fonte de dados, coleta automatizada via web scraping, pipeline ETL e pré-processamento, com análise exploratória (EDA). A fonte escolhida foi o site books.toscrape.com, plataforma pública para prática de raspagem. Foram coletados 577 registros de livros em 50 gêneros literários, contendo título, preço, rating, estoque, gênero, disponibilidade e URL. Após o ETL foram adicionados dois campos derivados: rating categórico e preço normalizado (Min-Max), resultando em 576 registros limpos com 8 colunas. A análise revelou que 100% dos livros estavam em estoque, com preço médio de £34,97 (intervalo £10,01–£59,99), distribuição de ratings aproximadamente uniforme entre 1 e 5 estrelas e correlação quase nula entre preço e avaliacao (r = 0,023). O gênero Suspense apresentou o maior preço médio (£58,33) e Crime o menor (£10,97). O dataset construído servirá de base para as próximas fases de mineração e para o dashboard final da disciplina.

Keywords—web scraping; mineração de dados; KDD; ETL; análise exploratória; livros online; BeautifulSoup; pandas.

I. INTRODUÇÃO

O crescimento acelerado do comércio eletrônico gerou volumes massivos de dados publicamente acessíveis na web, tornando o web scraping uma técnica fundamental dentro do processo de Descoberta de Conhecimento em Bases de Dados (KDD). Este trabalho prático aplica esse processo ao domínio de livros online, utilizando o site books.toscrape.com como fonte de dados estruturados.

O site foi criado especificamente para prática de raspagem de dados, sem autenticação, sem restrições relevantes em seu robots.txt e sem conteúdo dinâmico baseado em JavaScript, tornando-o ideal para fins acadêmicos.

As perguntas de pesquisa que motivam este trabalho são:

- Existe correlação entre o preço e a avaliação (rating) de um livro?
- Quais gêneros literários apresentam maior custo médio?
- A disponibilidade em estoque está associada ao preço ou avaliação?

As seções seguintes apresentam a fundamentação teórica (Sec. II), a metodologia detalhada (Sec. III), os resultados da análise exploratória (Sec. IV) e as conclusões do trabalho (Sec. V).

II. FUNDAMENTAÇÃO TEÓRICA

A. KDD — Knowledge Discovery in Databases

O processo KDD, formalizado por Fayyad et al. [1], descreve um pipeline sistemático para extrair conhecimento útil de dados brutos. As etapas clássicas são: (1) Seleção, (2) Pré-processamento, (3) Transformação, (4) Mineração de Dados e (5) Interpretação/Avaliação. Este trabalho cobre as três primeiras etapas, preparando a base para as fases subsequentes de mineração efetiva.

B. Web Scraping

Web scraping e a técnica de coleta automatizada de dados em páginas HTML. Ferramentas como BeautifulSoup permitem navegar pela árvore DOM e extrair elementos por seletores CSS, tags ou atributos [2]. A ética do scraping é avaliada pelo robots.txt do site e por seus termos de uso. O books.toscrape.com não apresenta restrições relevantes em nenhum dos dois, sendo um ambiente seguro e ético para prática acadêmica.

C. Pipeline ETL

ETL (Extract, Transform, Load) é o processo de extrair dados de uma fonte, transformá-los (limpeza, normalização, conversão de tipos) e carregá-los em repositório estruturado. No contexto de web scraping, a extração coincide com a raspagem do HTML; a transformação envolve o tratamento dos dados brutos; e a carga refere-se ao armazenamento em CSV [3].

D. Pré-processamento de Dados

O pré-processamento abrange o tratamento de valores ausentes, remoção de duplicatas, identificação de outliers via IQR, normalização (Min-Max Scaling) e discretização de variáveis contínuas. Essas transformações aumentam a qualidade do dataset e preparam os dados para algoritmos de mineração [4].

III. METODOLOGIA

A. Fonte de Dados

O site books.toscrape.com é uma plataforma de simulação de livraria online, com aproximadamente 1000 títulos organizados em 50 categorias. Cada livro possui página própria com preço, rating e quantidade em estoque. O site não utiliza JavaScript para renderização, tornando requisições HTTP diretas suficientes para a coleta.

B. Campos Coletados

Foram definidos sete campos de coleta, atendendo ao requisito de pelo menos seis campos (3 numéricos + 2 categóricos):

Campo	Tipo	Descrição
título	Texto	Nome do livro
preço	Numérico	Preço em libras (GBP)
rating	Numérico	Avaliação de 1 a 5
estoque	Numérico	Qtd. disponível
gênero	Categórico	Gênero literário
disponibilidade	Categórico	In stock / Out of stock
url	Texto	URL da página

Tabela I. Campos coletados no scraping.

C. Processo de Scraping (src/scraper.py)

O script utiliza as bibliotecas requests [5] e BeautifulSoup4 [2]. O fluxo e: (1) listar as 50 categorias na página inicial; (2) para cada categoria, percorrer todas as páginas de listagem; (3) para cada livro, acessar sua página individual para obter o campo estoque. Um delay de 200 ms entre requisições e 300 ms entre páginas é aplicado por respeito ao servidor. O rating bruto vem como classe CSS textual ("One"..."Five") e é convertido para inteiro via dicionário. A coleta foi limitada a 25 livros por categoria para controle de tempo de execução.

D. Pipeline ETL (src/etl.py)

O módulo ETL realiza as transformações sobre o CSV bruto:

- Padronização de tipos: conversão de string para float/int, normalização de capitalização dos gêneros.
- Remoção de duplicatas: critério composto título + genero (1 duplicata encontrada e removida).

- Tratamento de nulos: imputação pela mediana do preço por gênero, preservando heterogeneidade entre categorias.
- Detecção de outliers via IQR: documentados e mantidos.
- Discretização: campo rating_cat com rótulos Muito Ruim, Ruim, Regular, Bom, Excelente.
- Normalização Min-Max: campo preco_normalizado em [0,1] para uso futuro em algoritmos de ML.

E. Diagrama do Fluxo ETL

```
[books.toscrape.com]
scraper.py  (requests + BS4)
            ↓
livros_raw.csv  (577 linhas,
        7 campos)
            ↓
     etl.py  (limpeza +
       normalizacao)
            ↓
  livros_final.csv  (576
     linhas, 8 campos)
            ↓
     analise.py  (EDA +
       visualizacoes)
```

Figura 1. Diagrama do pipeline ETL.

F. Ferramentas Utilizadas

Biblioteca	Versão	Função
Python	3.12	Linguagem base
requests	2.31.0	Requisições HTTP
BeautifulSoup4	4.12.3	Parsing HTML
pandas	2.2.2	Manipulacao dados
matplotlib	3.8.4	Visualizações
seaborn	0.13.2	Gráficos estatísticos
lxml	5.2.1	Parser HTML rápido

Tabela II. Ferramentas e versões utilizadas.

IV. RESULTADOS

A. Panorama Geral da Base

A Tabela III resume o estado quantitativo antes e depois da limpeza:

Métrica	Raw	Final
Registros	577	576
Campos	7	8
Duplicatas	1	0
Valores nulos	0	0
Gêneros	50	50
100% In stock	Sim	Sim

Tabela III. Comparativo antes/após limpeza.

O dataset final possui 576 registros em 50 gêneros literários distintos, com 8 colunas (3 métricas originais + 2 categóricas + URL/título + 2 derivadas), atendendo a todos os requisitos técnicos da atividade.

B. Estatísticas Descritivas

Estatística	preço (£)	rating
N	576	576
Média	34,97	2,91
Desvio	14,47	1,45
Mínimo	10,01	1
Q1	22,06	2
Mediana	35,78	3
Q3	47,63	4
Máximo	59,99	5

Tabela IV. Estatísticas descritivas.

O campo estoque apresentou variância zero (valor constante = 1 em todos os registros), impossibilitando análises de correlação envolvendo essa variável. Isso decorre de uma particularidade do site durante o

período de coleta: todos os livros encontrados estavam em estoque com quantidade unitária.

C. Distribuição de Preços

O histograma da Figura 2 revela distribuição aproximadamente uniforme entre £10 e £60. O boxplot por rating confirma que a dispersão de preços é similar em todas as categorias de avaliação, evidenciando ausência de relação linear entre preço e rating.

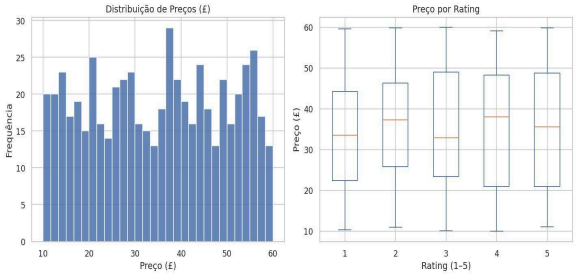

Figura 2. Distribuição de preços e boxplot por rating.

D. Distribuição de Ratings

A Figura 3 mostra a distribuição de livros por avaliação. O rating 1 é o mais frequente (136 livros, 23,6%), seguido do rating 5 (115; 20,0%), rating 2 (113; 19,6%), rating 3 (110; 19,1%) e rating 4 (102; 17,7%). A distribuição relativamente uniforme difere do padrão habitual de plataformas reais, onde há tipicamente polarização em notas extremas — sugerindo distribuição artificial no site de prática.

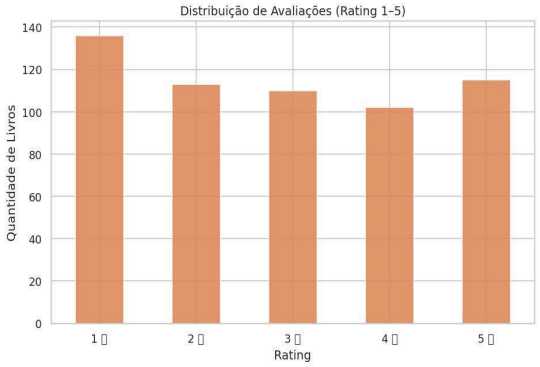

Figura 3. Distribuição de avaliações (rating 1–5).

E. Distribuição por Género

A Figura 4 exibe os 15 gêneros com maior volume. Os generos Mystery, Historical Fiction, Childrens, Sequential Art, Fiction, Romance, Default, Add A Comment, Nonfiction, Young Adult e Food And Drink lideram com 25 livros cada — o limite máximo por categoria aplicado no scraping. Fantasy aparece com 24 e Classics e Poetry com 19, indicando que esses gêneros possuem coleções menores no site.

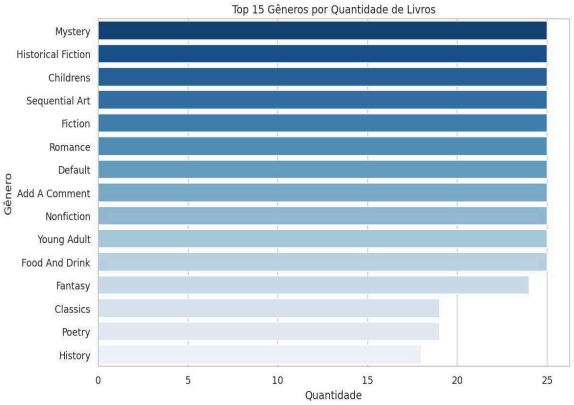

Figura 4. Top 15 gêneros por quantidade de livros.

F. Preço Médio por Gênero

A Figura 5 apresenta o preço médio dos gêneros com maior variação. Suspense lidera com £58,33, seguido por Novels (£54,81) e Politics (£53,61). No extremo inferior, Crime apresenta média de £10,97, seguido de Academic (£13,12) e Adult Fiction (£15,36). Essa heterogeneidade inter-gênero justificou o uso de mediana por gênero na imputação de valores nulos durante o ETL.

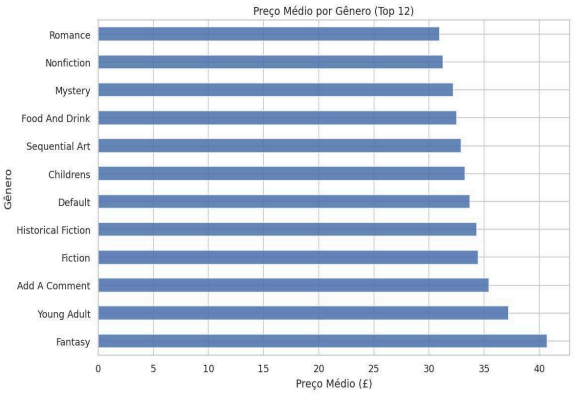

Figura 5. Preço médio por gênero (Top 12).

G. Disponibilidade em Estoque

O gráfico da Figura 6 confirma que 100% dos 576 livros estão classificados como "In stock". Isso impossibilita a investigação direta da terceira pergunta de pesquisa — associação entre disponibilidade e preco/rating — pela ausência de variabilidade na variável categórica. Essa limitação é documentada como restrição do trabalho.

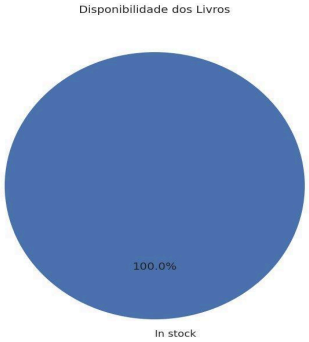

Figura 6. Disponibilidade dos livros (100% In stock).

H. Correlação entre Variáveis Numéricas

A Figura 7 apresenta a matriz de correlação. A correlação entre preço e rating é quase nula (r = 0,023), confirmando ausência de relação linear entre as variáveis — o preço de um livro não influencia sua avaliação neste dataset. A correlação entre preço e preco_normalizado é perfeita (r = 1,00) por definição da transformação Min-Max. O campo estoque foi excluído da análise por variância zero.

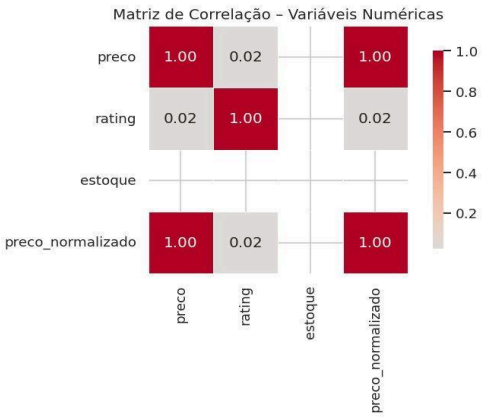

Figura 7. Matriz de correlação das variáveis numéricas.

I. Distribuição do Estoque

A Figura 8 confirma graficamente o valor constante de estoque = 1 para todos os 576 registros, com desvio padrão nulo. Essa homogeneidade impossibilita análises baseadas nessa variável no presente dataset e será abordada como limitação a ser superada nas próximas fases.

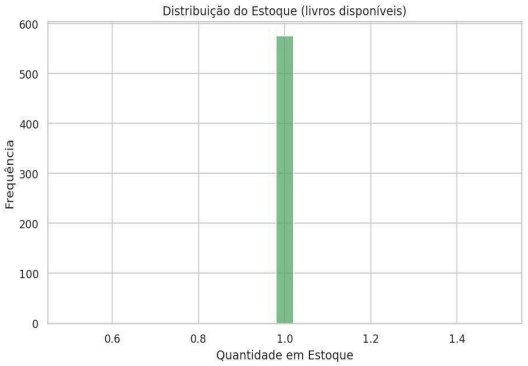

Figura 8. Distribuição do estoque dos livros.

J. Posição no Processo KDD

O dataset encontra-se concluindo a etapa de Pré-processamento e Transformação do KDD. As próximas etapas previstas são: (1) Mineracao — classificação (Decision Tree para prever rating_cat), agrupamento (k-Means por faixa de preço e genero) e regras de associação (Apriori); (2) Interpretação/Avaliação dos padrões descobertos; (3) Dashboard interativo ao final do semestre.

V. CONCLUSÃO

Este trabalho implementou com sucesso a Fase 1 do processo KDD, cobrindo seleção da fonte, coleta via scraping, pipeline ETL e análise exploratória. O pipeline é reproduzível, documentado e atende a todos os requisitos técnicos e éticos da atividade.

Os principais achados foram: (1) ausência de correlação significativa entre preço e rating (r = 0,023); (2) expressiva heterogeneidade de preço entre gêneros (de £10,97 em Crime a £58,33 em Suspense); e (3) disponibilidade uniforme de 100%, impossibilitando a análise da terceira pergunta de pesquisa com os dados atuais.

As principais dificuldades encontradas foram: o tempo de coleta elevado em decorrência do acesso individual a cada página de livro para obter o estoque, a homogeneidade do campo estoque (variância zero) e o limite de 25 livros por categoria que restringiu o volume total a 577 registros (em vez dos ~1000 títulos disponíveis no site).

Como próximos passos, o dataset será expandido removendo o limite por categoria, e será utilizado nas fases seguintes da disciplina com algoritmos de classificação, agrupamento e regras de associação, culminando em um dashboard interativo de visualização dos resultados obtidos ao longo do semestre.

REFERÊNCIAS

[1] U. M. Fayyad, G. Piatetsky-Shapiro e P. Smyth, "From Data Mining to Knowledge Discovery in Databases," *AI Magazine,* vol. 17, no. 3, pp. 37–54, 1996.

[2] L. Richardson, "Beautiful Soup Documentation," Beautiful Soup 4.12. [Online]. Disponível em: https://www.crummy.com/software/BeautifulSoup/bs4/doc/. Acesso em: 2025.

[3] R. Kimball e M. Ross, *The Data Warehouse Toolkit,* 3a ed. Indianapolis: Wiley, 2013.

[4] J. Han, M. Kamber e J. Pei, *Data Mining: Concepts and Techniques,* 3a ed. Waltham: Morgan Kaufmann, 2012.

[5] K. Reitz, "Requests: HTTP for Humans," Requests 2.31. [Online]. Disponível em: https://docs.python-requests.org/. Acesso em: 2025.

[6] W. McKinney, *Python for Data Analysis,* 3a ed. Sebastopol: O'Reilly Media, 2022.

[7] books.toscrape.com. "Books to Scrape: A website for web scraping practice." [Online]. Disponível em: http://books.toscrape.com. Acesso em: 2025.